

# Modelo sugerido para fecundidad en áreas pequeñas

Equipo de Proyecciones-Fecundidad

2026-06-04

## Modelo Espacio-Temporal Bayesiano para Tasas de Fecundidad

### Conceptos Demográficos Básicos

Antes de entrar en el desarrollo del predictor lineal, es fundamental definir matemáticamente los dos indicadores clave que calcula este modelo:

1. **ASFR (Age-Specific Fertility Rate - Tasa Específica de Fecundidad por Edad):** Mide la intensidad de la fecundidad en grupos de edad específicos (usualmente de 5 años: 15-19, 20-24, ..., 45-49) para una región  $i$  y periodo  $t$ . Representa la frecuencia con la que las mujeres de ese grupo tienen hijos. Su fórmula de cálculo directo tradicional es:

$$\text{ASFR}_{it,a} = \frac{B_{it,a}}{W_{it,a}}$$

Donde: -  $B_{it,a}$  es el total de nacimientos ocurridos en las mujeres del grupo de edad  $a$ . -  $W_{it,a}$  es el total de mujeres (población expuesta a mitad de periodo) en el grupo de edad  $a$ .

2. **TFR (Total Fertility Rate - Tasa Global de Fecundidad):** Es el indicador sintético más importante en demografía. Representa el número promedio de hijos que tendría una mujer a lo largo de toda su vida reproductiva si experimentara las tasas de fecundidad por edad (ASFR) calculadas para esa región  $i$  y periodo  $t$ . Al trabajar con grupos de edad quinquenales (bloques de 5 años), la fórmula matemática de agregación es:

$$\text{TFR}_{it} = 5 \times \sum_{a=1}^7 \text{ASFR}_{it,a}$$

Donde  $a$  indexa los 7 grupos de edad reproductiva estandarizados (desde 15-19 hasta 45-49). Se multiplica por 5 porque cada mujer permanece exactamente cinco años expuesta al riesgo reproductivo de cada grupo de edad a medida que envejece.

El objetivo de este modelo es estimar estos indicadores en áreas pequeñas o regiones, corrigiendo la alta variabilidad o “ruido” que tienen los datos muestrales directos. Para lograrlo, se implementa un Modelo Lineal Generalizado Mixto Bayesiano utilizando una **regresión de Poisson**, procesada bajo el motor de estimación INLA (Integrated Nested Laplace Approximations).

---

### Estrategias de Modelado por Edad: Enfoque Estratificado vs. Enfoque Global

Al construir este modelo espacio-temporal, existen dos filosofías metodológicas radicalmente distintas para abordar la variable edad: **Ajustar modelos independientes (estratificación)** o **Ajustar un modelo global con efectos estructurados (enfoque unificado)**.

## Enfoque 1: Modelado Estratificado por Separado (Código Original)

En esta aproximación, el conjunto de datos se divide en 7 subconjuntos (uno por cada grupo de edad) y se ejecuta el motor `inla()` de forma independiente en un ciclo iterativo.

- **Ventajas:** Es conceptualmente intuitivo y elimina por completo cualquier interacción compleja entre la edad y el espacio/tiempo dentro del código, ya que cada grupo tiene su propia escala y parámetros.
- **Desventajas Críticas:**
  1. **Aislamiento Estadístico:** Asume de manera irreal que lo que ocurre en un grupo de edad es biológica y socialmente independiente de lo que ocurre en los grupos adyacentes. Rompe la continuidad natural de la curva de fecundidad.
  2. **Incapacidad de Compartir Fuerza (Borrowing Strength):** Si una región tiene pocos datos o muestras rezagadas en el grupo de “45-49”, el modelo no puede apoyarse en la tendencia del grupo “40-44” para estabilizar la estimación.
  3. **Inflexibilidad y Costo Computacional:** Requiere compilar y ejecutar el algoritmo de INLA tantas veces como estratos existan (7 iteraciones), duplicando el almacenamiento de resultados intermedios.

## Enfoque 2: Modelado Global con Estructura Temporal en Edad (Enfoque Recomendado)

En este enfoque, toda la base de datos se introduce simultáneamente al motor de estimación. La curva de fecundidad se captura asignando un efecto aleatorio estructurado a la variable edad, específicamente un **Random Walk de Orden 2 (rw2)**.

- **Ventajas Cruciales:**
  1. **Preservación de la Curva de Fecundidad:** El efecto `rw2` entiende implícitamente que la fecundidad es un proceso biológico continuo que sube de forma cóncava a los veintitantos y desciende gradualmente hacia los cuarenta. Penaliza cambios o brincos erráticos entre edades contiguas.
  2. **Transferencia de Información Coherente:** Permite que los grupos de edad con menor cantidad de eventos o mayor subregistro (como los extremos 15-19 o 45-49) se estabilicen utilizando la tendencia estructural de los grupos centrales de mayor exposición.
  3. **Eficiencia y Escalabilidad:** El modelo corre en un único proceso iterativo global, reduciendo el margen de error técnico y permitiendo, en pasos futuros, añadir interacciones complejas (por ejemplo, evaluar si el efecto de la edad cambia sutilmente entre periodos o regiones mediante interacciones de tipo Knorr-Held).

| Dimensión Analítica                   | Enfoque Estratificado (Original)              | Enfoque Global con <code>rw2</code> (Nuevo)          |
|---------------------------------------|-----------------------------------------------|------------------------------------------------------|
| <b>Llamadas a <code>inla()</code></b> | Múltiples (7 veces, una por grupo)            | Única (1 vez con toda la matriz)                     |
| <b>Relación entre edades</b>          | Independencia matemática absoluta             | Dependencia continua y suavizada estructuralmente    |
| <b>Comportamiento en extremos</b>     | Alta susceptibilidad a variaciones muestrales | Estabilizado mediante “préstamo de fuerza” adyacente |
| <b>Tratamiento de la curva</b>        | No estructurado / Ignorado                    | Modelado de segundas diferencias continuas           |

## 1. La Estructura de los Datos (La Verosimilitud Global)

Bajo el modelo unificado, los nacimientos observados en todas las combinaciones regionales, temporales y etarias se tratan de forma conjunta dentro de la distribución de Poisson:

$$Y_{ita} \sim \text{Poisson}(\mu_{ita})$$

Donde la media de nacimientos esperados  $\mu_{ita}$  se define como:

$$\mu_{ita} = N_{ita} \times \lambda_{ita}$$

Donde para una región  $i$ , un periodo de tiempo  $t$  y un grupo de edad  $a$ : \*  $Y_{ita}$  es el número observado de nacimientos (**births**). \*  $N_{ita}$  es el número total de mujeres expuestas o en riesgo (**women**), que funciona como el **offset** (exposición poblacional). \*  $\lambda_{ita}$  es la Tasa Específica de Fecundidad Suavizada (ASFR) final calculada para dicho estrato.

---

## 2. El Predictor Lineal Unificado

Para conectar los datos con los componentes explicativos estructurales, aplicamos la función de enlace logarítmica:

$$\ln(\mu_{ita}) = \ln(N_{ita}) + \ln(\lambda_{ita})$$

Estableciendo el nuevo predictor lineal expandido para la tasa logarítmica como:

$$\ln(\lambda_{ita}) = \beta_0 + \alpha_a + u_i + v_i + \gamma_t$$

Donde los componentes se definen matemáticamente de la siguiente manera:

### A. El Intercepto ( $\beta_0$ )

Efecto fijo global. Nivel base promedio de la fecundidad nacional expresada en escala logarítmica para todo el espectro de tiempo, espacio y edad.

### B. El Componente de Edad Estructurado: Random Walk 2 ( $\alpha_a$ )

En lugar de tratar las edades como factores inconexos, se define un proceso intrínsecamente autorregresivo del tiempo/orden en los niveles de edad. El modelo **rw2** asume que la variación de las tasas entre un grupo de edad y sus predecesores está dictada por segundas diferencias normales centradas en cero:

$$\Delta^2 \alpha_a = \alpha_a - 2\alpha_{a-1} + \alpha_{a-2} \sim \text{Normal}(0, \sigma_\alpha^2)$$

Esto restringe la forma de la curva de fecundidad por edad a trayectorias suaves y biológicamente realistas a lo largo de los 7 grupos indexados.

### C. El Componente Espacial: Modelo BYM2 ( $u_i + v_i$ )

El riesgo geográfico se descompone de forma idéntica en dos efectos latentes: 1. **Efecto Espacial Estructurado ( $u_i$ )**: Sigue una distribución Condicional Autorregresiva (CAR) basada en la matriz de vecindad contigua (**Amat**), forzando el suavizamiento regional. 2. **Efecto Espacial No Estructurado ( $v_i$ )**: Distribución Normal IID, encargada de absorber el ruido local único e independiente de la geografía vecina.

### D. El Componente Temporal: Random Walk 2 ( $\gamma_t$ )

Controla la inercia demográfica en el tiempo a través de periodos quinquenales consecutivos bajo una penalización de segundas diferencias:

$$\Delta^2 \gamma_t = \gamma_t - 2\gamma_{t-1} + \gamma_{t-2} \sim \text{Normal}(0, \sigma_\gamma^2)$$


---

### 3. Requisitos de Entrada: Estructura de Datos y Archivos Requeridos

Para que el modelo global compile correctamente en RStudio, las estructuras deben respetar estrictamente los siguientes formatos.

#### 1. El Archivo de Datos Principal (**df**)

Debe cargarse como un único dataframe plano consolidado. Cada fila mapea el cruce exacto de las tres dimensiones fundamentales:

- **region** (*Factor/Character*): Nombre o identificador geográfico. Debe emparejar simétricamente con los nombres de la matriz de adyacencia.
- **period** (*Factor/Character*): Ventanas temporales (ej. "2005-2009", "2010-2014").
- **agegroup** (*Factor/Character*): Grupos quinquenales reproductivos ("15-19" hasta "45-49").
- **women** (*Numérico entero*): Total de población expuesta. Denominador oficial.
- **births** (*Numérico entero*): Eventos de conteo registrados. Numerador oficial.

Tabla de ejemplo unificada (**head(df)**):

| region | period    | agegroup | women | births |
|--------|-----------|----------|-------|--------|
| Norte  | 2005-2009 | 15-19    | 2300  | 180    |
| Norte  | 2005-2009 | 20-24    | 2900  | 440    |
| Centro | 2005-2009 | 15-19    | 1900  | 155    |
| ...    | ...       | ...      | ...   | ...    |

#### 2. La Matriz de Adyacencia Espacial (**Amat**)

Matriz cuadrada simétrica de dimensiones  $R \times R$ : \* Contiene valores binarios: 1 para vecinos directos con frontera compartida, 0 para no vecinos. \* Diagonal fija en 0.

#### 4. De la ASFR a la TFR (Consolidación Final)

Tras procesar el ajuste unificado, se extraen las estimaciones transformadas a su escala natural por medio de la función exponencial:

$$\text{ASFR}_{ita} = \lambda_{ita} = e^{\beta_0 + \alpha_a + u_i + v_i + \gamma_t}$$

Finalmente, para consolidar la Tasa Global de Fecundidad (TFR) para cada combinación de región  $i$  y periodo  $t$ , el script agrupa las filas y suma los valores ponderados por la amplitud del intervalo quinquenal:

$$\text{TFR}_{it} = 5 \times \sum_{a=1}^7 \text{ASFR}_{ita}$$

#### Apéndice de Código: Comparativa de Scripts en R

A continuación se anexan de forma explícita los bloques de código correspondientes a los dos enfoques descritos.

#### Bloque A: Código Original (Modelado Separado en Bucle por Edad)

```

# Instalar INLA si no está presente en tu entorno:
# install.packages("INLA", repos=c(getOption("repos"), INLA="https://r-inla-download.org"), dep=TRUE)

library(SUMMER)
library(INLA)
library(dplyr)
library(tidyr)

set.seed(123)

# -----
# 1. Crear datos inventados con Intervalos Quinquenales (3 periodos)
# -----
regions <- c("Norte", "Centro", "Sur")
periods_list <- c("2005-2009", "2010-2014", "2015-2019")
ages <- c("15-19", "20-24", "25-29", "30-34", "35-39", "40-44", "45-49")

df <- expand.grid(region = regions,
                  period = periods_list,
                  agegroup = ages)

# Mujeres expuestas
df$women <- round(runif(nrow(df), 1500, 4000))

# ASFR base por edad (inventado)
age_effect <- c(0.08, 0.15, 0.12, 0.08, 0.04, 0.01, 0.002)

# Nacimientos simulados
df$births <- rbinom(nrow(df), size = df$women,
                  prob = rep(age_effect, each = length(regions) * length(periods_list)))

# -----
# 2. Matriz de adyacencia espacial
# -----
adj <- matrix(0, 3, 3)
rownames(adj) <- colnames(adj) <- regions
adj["Norte", "Centro"] <- 1
adj["Centro", "Norte"] <- 1
adj["Centro", "Sur"] <- 1
adj["Sur", "Centro"] <- 1
Amat <- adj

# Creación de índices numéricos requeridos por INLA para los efectos aleatorios
df$region_idx <- as.numeric(factor(df$region, levels = regions))

# Mapeo de los textos de periodos a números secuenciales (1, 2, 3...) para el modelo temporal
df$period_idx <- as.numeric(factor(df$period, levels = periods_list))

# -----
# 3. Ajustar modelo Bayesiano Espacio-Temporal por Edad (Poisson)
# -----
result_list <- list()

```

```

for (a in ages) {

  df_age <- df %>% filter(agegroup == a)

  # Estructura del modelo lineal generalizado para conteos
  formula <- births ~ 1 +
    f(region_idx, model = "bym2", graph = Amat) +
    f(period_idx, model = "rw2")

  # AJUSTE CRÍTICO: family = "poisson" y el argumento E para fijar el offset poblacional
  fit <- inla(formula,
    family = "poisson",
    data = df_age,
    E = df_age$women, # Define la exposición (población en riesgo)
    control.predictor = list(compute = TRUE))

  # Al usar el parámetro 'E', INLA calcula la tasa pura (lambda).
  # summary.fitted.values$mean nos devuelve directamente la ASFR suavizada en su escala original.
  df_age$asfr_suavizada <- fit$summary.fitted.values$mean
  df_age$asfr_suavizada_lower <- fit$summary.fitted.values$`0.025quant`
  df_age$asfr_suavizada_upper <- fit$summary.fitted.values$`0.975quant`
  result_list[[a]] <- df_age
}

summary(fit)

# -----
# 4. Consolidar ASFR Suavizadas y Calcular TFR = 5 * sum(ASFR)
# -----
pred_all <- bind_rows(result_list)

# Agrupación exacta por la columna 'period'
TFR <- pred_all %>%
  group_by(region, period) %>%
  summarise(
    TFR_lower = 5 * sum(asfr_suavizada_lower),
    TFR = 5 * sum(asfr_suavizada),
    TFR_upper = 5 * sum(asfr_suavizada_upper), .groups = "drop")

# -----
# 5. Imprimir Resultados Finales
# -----
print(TFR)

```

## Bloque B: Código Modificado Nuevo (Ajuste Global con Edad Estructurada en rw2)

```

# Instalar INLA si no está presente en tu entorno:
# install.packages("INLA", repos=c(getOption("repos"),
INLA="https://r-inla-download.org"), dep=TRUE)

library(SUMMER)
library(INLA)
library(dplyr)

```

```

library(tidyr)

set.seed(123)

# -----
# 1. Crear datos inventados con Intervalos Quinquenales (3 periodos)
# -----
regions <- c("Norte", "Centro", "Sur")
periods_list <- c("2005-2009", "2010-2014", "2015-2019")
ages <- c("15-19", "20-24", "25-29", "30-34", "35-39", "40-44", "45-49")

df <- expand.grid(region = regions,
                  period = periods_list,
                  agegroup = ages)

df$women <- round(runif(nrow(df), 1500, 4000))
age_effect <- c(0.08, 0.15, 0.12, 0.08, 0.04, 0.01, 0.002)

df$births <- rbinom(nrow(df), size = df$women,
                   prob = rep(age_effect,
                              each = length(regions) * length(periods_list)))

# -----
# 2. Matriz de adyacencia espacial e Índices
# -----
adj <- matrix(0, 3, 3)
rownames(adj) <- colnames(adj) <- regions
adj["Norte", "Centro"] <- 1
adj["Centro", "Norte"] <- 1
adj["Centro", "Sur"] <- 1
adj["Sur", "Centro"] <- 1
Amat <- adj

df$region_idx <- as.numeric(factor(df$region, levels = regions))
df$period_idx <- as.numeric(factor(df$period, levels = periods_list))

# NUEVO: Índice numérico para el grupo de edad
df$age_idx <- as.numeric(factor(df$agegroup, levels = ages))

# -----
# 3. Ajustar modelo Bayesiano Global (Un solo FIT)
# -----

# Añadimos f(age_idx, model = "rw2")
formula_global <- births ~ 1 +
  f(age_idx, model = "rw2") +
  f(region_idx, model = "bym2", graph = Amat) +
  f(period_idx, model = "rw2")

fit_global <- inla(formula_global,
                  family = "poisson",
                  data = df,
                  E = df$women,

```

```

control.predictor = list(compute = TRUE))

# Extraer las ASFR estimadas directamente del modelo
df$asfr_suavizada <- fit_global$summary.fitted.values$mean
df$asfr_suavizada_lower <- fit_global$summary.fitted.values$`0.025quant`
df$asfr_suavizada_upper <- fit_global$summary.fitted.values$`0.975quant`

# -----
# 4. Consolidar y Calcular TFR = 5 * sum(ASFR)
# -----
# NOTA SOBRE LOS INTERVALOS DE LA TFR:
# Sumar los cuantiles directos (lower y upper) asume correlación perfecta.
# Para el ejemplo mantenemos tu lógica, pero la TFR puntual ahora es mucho más robusta.

TFR_global <- df %>%
  group_by(region, period) %>%
  summarise(
    TFR_lower = 5 * sum(asfr_suavizada_lower),
    TFR       = 5 * sum(asfr_suavizada),
    TFR_upper = 5 * sum(asfr_suavizada_upper),
    .groups = "drop"
  )

# -----
# 5. Imprimir Resultados Finales
# -----
summary(fit_global)
print(TFR_global)

```

## Referencias

- Gómez-Rubio, Virgilio (2020). Bayesian Inference with INLA. Chapman & Hall/CRC Press. Boca Raton, FL.
- Saha, U.R., Das, S., Baffour, B. et al. Small Area Estimation of Age-Specific and Total Fertility Rates in Bangladesh. *Spat Demogr* 11, 2 (2023). <https://doi.org/10.1007/s40980-022-00113-1>
- Besag, J., York, J., & Mollié, A. (1991). Bayesian image restoration, with two-dimensional spatial dependence. *Annals of the Institute of Statistical Mathematics*, 43(1), 1-59. <https://doi.org/10.1007/BF00116466> (Referencia fundamental para comprender el componente de efectos aleatorios espaciales y la formulación inicial del modelo BYM).
- Blangiardo, M., & Cameletti, M. (2015). *Spatial and Spatio-temporal Bayesian Models with R-INLA*. John Wiley & Sons. (Libro de texto clave y guía práctica para modelar estructuras temporales como el Random Walk de Orden 2 (RW2) y estructuras espaciales dentro de INLA).
- Li, Z., Hsiao, Y., Godwin, J., Martin, B. D., Wakefield, J., & Clark, S. J. (2020). Changes in the spatial distribution of the under-five mortality rate in small areas of 29 countries in sub-Saharan Africa. *PLOS ONE*, 15(1), e0227506. <https://doi.org/10.1371/journal.pone.0210645> (Estudio metodológico de referencia que utiliza el paquete **SUMMER** en R y modelos de suavizamiento espacio-temporales mediante aproximaciones Laplace anidadas integradas).
- Preston, S. H., Heuveline, P., & Guillot, M. (2001). *Demography: Measuring and Modeling Population Processes*. Blackwell Publishers. (Manual clásico de demografía analítica que sustenta el desarrollo matemático del cálculo formal de las Tasas Específicas de Fecundidad (ASFR) y la fórmula de expansión para la Tasa Global de Fecundidad (TFR)).



Rue, H., Martino, S., & Chopin, N. (2009). Approximate Bayesian inference for latent Gaussian models by using integrated nested Laplace approximations. *Journal of the Royal Statistical Society: Series B (Statistical Methodology)*, 71(2), 319-392. <https://doi.org/10.1111/j.1467-9868.2008.00700.x> (*El artículo fundacional de la metodología INLA, donde se explica la aproximación analítica utilizada en lugar de las simulaciones MCMC*).

Simpson, D., Rue, H., Riebler, A., Martins, T. G., & Sørbye, S. H. (2017). Penalising model component complexity: A principled, practical approach to constructing priors. *Statistical Science*, 32(1), 1-28. <https://doi.org/10.1214/16-STS576> (*Artículo clave que justifica la reparameterización del modelo BYM al modelo BYM2, facilitando la interpretación del balance de variabilidad espacial estructurada y no estructurada*).