

Modelo sugerido para mortalidad de áreas pequeñas

Modelo Bayesiano Espacio-Temporal con INLA

La estimación de la mortalidad a nivel subnacional presenta un desafío estadístico fundamental conocido como el **problema de áreas pequeñas** (*Small Area Estimation*, SAE). En áreas con poca población —municipios, departamentos, grupos de edad específicos— los conteos de muertes son escasos, produciendo estimadores directos de alta variabilidad que resultan inútiles para la toma de decisiones en salud pública.

Sea D_{xrt} el número de muertes en el grupo de edad x , región r y período t , con exposición N_{xrt} . El estimador directo de la tasa de mortalidad es:

$$\hat{m}_{xrt}^{\text{directo}} = \frac{D_{xrt}}{N_{xrt}}, \quad \text{Var}(\hat{m}_{xrt}^{\text{directo}}) = \frac{m_{xrt}(1 - m_{xrt})}{N_{xrt}} \xrightarrow{N_{xrt} \rightarrow 0} \infty \quad (1)$$

Cuando la población expuesta N_{xrt} es pequeña —situación frecuente en grupos de edad infantil o en municipios rurales— la varianza del estimador directo se dispara, haciendo que las tasas crudas oscilen de un período a otro de forma que no refleja cambios reales en la mortalidad sino mero *ruido muestral*.

La solución estándar en demografía moderna es **tomar prestada fortaleza** (*borrow strength*) de áreas vecinas, grupos de edad adyacentes y períodos cercanos mediante un modelo estadístico que imponga suavidad.

¿Por qué un modelo Bayesiano jerárquico?

Los modelos jerárquicos Bayesianos son el estándar de oro para SAE por tres razones:

- 1. Regularización automática:** las distribuciones a priori actúan como regularizadores que reducen la varianza de los estimadores en áreas con poca información, a costa de una ligera desviación controlada del estimador directo.
- 2. Propagación completa de la incertidumbre:** a diferencia de métodos frecuentistas, la distribución posterior cuantifica la incertidumbre de cada estimación, permitiendo intervalos de credibilidad coherentes.
- 3. Incorporación de estructura demográfica conocida:** los efectos aleatorios estructurados (BYM2, RW1, RW2) codifican supuestos demográficos bien fundamentados como restricciones probabilísticas, no como supuestos rígidos.

1. Estructura de los datos

1.1. Naturaleza de los registros administrativos

Los **registros de defunciones** (actas de defunción, registros civiles, estadísticas vitales) constituyen un **censo de eventos**, no una muestra. La tabla 1 contrasta este contexto con el de las encuestas de hogares.

Encuestas de hogares	Registros demográficos
Muestra probabilística de hogares	Conteo completo (censo) de defunciones
Factor de expansión necesario	No requiere factor de expansión
Diseño muestral complejo (estratos, conglomerados)	Sin diseño muestral; es el universo
Varianza dominada por el diseño muestral	Varianza surge solo del proceso de conteo
Distribución apropiada: compleja (linearización de Taylor)	Distribución apropiada: Poisson
Modelos de encuestas (SUMMER::smoothDirect)	Modelos de conteos (INLA + Poisson)

Table 1: Comparación entre encuestas y registros demográficos.

1.2. Justificación de la distribución Poisson

Para conteos de eventos raros en una exposición conocida, el modelo estadístico natural es la distribución **Poisson**. Sea D_{xrt} el número de defunciones observadas:

$$D_{xrt} \mid \mu_{xrt} \sim \text{Poisson}(\mu_{xrt}), \quad \mu_{xrt} = N_{xrt} \cdot m_{xrt} \quad (2)$$

donde la propiedad fundamental de la distribución Poisson es:

$$\mathbb{E}[D_{xrt}] = \text{Var}(D_{xrt}) = \mu_{xrt} = N_{xrt} \cdot m_{xrt} \quad (3)$$

La igualdad media-varianza implica que:

$$\text{Var}(\hat{m}_{xrt}) = \text{Var}\left(\frac{D_{xrt}}{N_{xrt}}\right) = \frac{\mu_{xrt}}{N_{xrt}^2} = \frac{m_{xrt}}{N_{xrt}} \quad (4)$$

Este comportamiento es exactamente el que se espera de un proceso de conteo de muertes: la incertidumbre es proporcional a la inversa de la exposición.

Ventaja sobre el modelo Gaussiano para registros

El modelo Gaussiano asume $D_{xrt} \sim \mathcal{N}(\mu, \sigma^2)$ con varianza *constante*. Esto es incorrecto para conteos de defunciones por dos razones:

- **(i) Discretitud:** las muertes son enteros no negativos. El modelo Gaussiano asigna probabilidad positiva a valores negativos, lo cual es demográficamente absurdo. La distribución Poisson tiene soporte en $\{0, 1, 2, \dots\}$.
- **(ii) Heterocedasticidad natural:** la varianza de un conteo Poisson crece con la media. El modelo Gaussiano estándar ignora este patrón: sobreestima la precisión en áreas pequeñas (donde μ es bajo) o la subestima en áreas grandes. El modelo Poisson evita ambos problemas sin especificar una varianza separada.

1.3. El offset de exposición en INLA

En INLA, la exposición N_{xrt} se introduce como **offset** mediante el argumento `E = population`. Esto es equivalente a modelar la tasa en escala logarítmica:

$$\log(\mu_{xrt}) = \underbrace{\log(N_{xrt})}_{\text{offset fijo}} + \eta_{xrt} \quad (5)$$

donde η_{xrt} es el predictor lineal. De este modo:

$$m_{xrt} = \exp(\eta_{xrt}) \quad (6)$$

Esto explica por qué los `fit$summary.fitted.values$mean` de INLA con `E = population` ya representan la tasa de mortalidad m_{xrt} directamente, **sin** necesidad de dividir por N_{xrt} nuevamente.

2. Especificación completa del modelo jerárquico

2.1. El modelo en tres niveles

Modelo jerárquico Bayesiano completo

Nivel 1 — Verosimilitud (proceso de observación):

$$D_{xrt} \mid m_{xrt} \sim \text{Poisson}(N_{xrt} \cdot m_{xrt})$$

Nivel 2 — Predictor lineal (escala logarítmica):

$$\log(m_{xrt}) = \mu + \alpha_x + \psi_r + \gamma_t + \delta_{rt}$$

donde $\psi_r = \phi_r + \theta_r$ es el efecto espacial BYM2.

Nivel 3 — Distribuciones a priori:

$$\alpha_x \sim \text{RW1}(\sigma_\alpha^2), \quad \phi_r \sim \text{ICAR}(W), \quad \theta_r \sim \mathcal{N}(0, \sigma_\theta^2), \quad \gamma_t \sim \text{RW2}(\sigma_\gamma^2), \quad \delta_{rt} \stackrel{\text{iid}}{\sim} \mathcal{N}(0, \sigma_\delta^2)$$

2.2. Efecto de edad: Random Walk de orden 1 (RW1)

El efecto de edad α_x captura el patrón de la curva de mortalidad por edad. Se modela como un **proceso de Random Walk de orden 1**, que especifica que el *incremento* entre grupos de edad consecutivos es estocástico e independiente:

$$\alpha_x = \alpha_{x-1} + \varepsilon_x, \quad \varepsilon_x \stackrel{\text{iid}}{\sim} \mathcal{N}(0, \sigma_\alpha^2) \quad (7)$$

La distribución conjunta resultante es:

$$p(\boldsymbol{\alpha} \mid \sigma_\alpha^2) \propto \exp \left\{ -\frac{1}{2\sigma_\alpha^2} \sum_x (\alpha_x - \alpha_{x-1})^2 \right\} \quad (8)$$

con matriz de precisión $\mathbf{Q}_\alpha = \sigma_\alpha^{-2} \mathbf{D}^\top \mathbf{D}$, donde $\mathbf{D}$ es la matriz de primeras diferencias (rango deficiente en 1).

La restricción `constr = TRUE` impone $\sum_x \alpha_x = 0$, garantizando identificabilidad con el intercepto μ .

2.3. Efecto espacial: BYM2

El efecto espacial combina **autocorrelación espacial estructurada** y **heterogeneidad no estructurada** mediante el modelo BYM2 (Riebler et al., 2016):

$$\psi_r = \frac{1}{\sigma_\psi} \left[\sqrt{\rho} \cdot \phi_r^* + \sqrt{1 - \rho} \cdot \theta_r \right] \quad (9)$$

donde:

- $\phi_r^* \sim \text{ICAR}(W)$: componente estructurado (autocorrelación espacial), estandarizado para que $\text{Var}(\phi_r^*) \approx 1$.
- $\theta_r \sim \mathcal{N}(0, 1)$: componente no estructurado (heterogeneidad pura).
- $\rho \in [0, 1]$: parámetro de mezcla *estimado por los datos*; $\rho \approx 1$ indica dominancia del patrón espacial; $\rho \approx 0$ indica heterogeneidad no estructurada.
- σ_ψ : desviación estándar marginal total.

El componente **ICAR** (Intrinsic Conditional AutoRegressive) especifica la distribución condicional completa:

$$\phi_r \mid \phi_{-r} \sim \mathcal{N} \left(\frac{1}{n_r} \sum_{j \sim r} \phi_j, \frac{\sigma_\phi^2}{n_r} \right) \quad (10)$$

donde n_r es el número de vecinos de la región r y la suma corre sobre regiones j adyacentes a r (denotado $j \sim r$).

La distribución conjunta ICAR es:

$$p(\phi \mid \sigma_\phi^2) \propto \exp \left\{ -\frac{1}{2\sigma_\phi^2} \phi^\top \mathbf{Q}_W \phi \right\}, \quad \mathbf{Q}_W = \text{diag}(\mathbf{n}) - \mathbf{W} \quad (11)$$

donde $\mathbf{W}$ es la matriz de adyacencia y $\mathbf{Q}_W$ es el **Laplaciano del grafo**.

La innovación del BYM2 sobre el BYM original (Besag et al., 1991) es la **parametrización escalada**: ϕ^* se estandariza de forma que $\text{Var}(\phi_r^*) \approx 1$, lo que hace que ρ sea directamente interpretable como la *proporción de varianza explicada por la estructura espacial*.

2.4. Efecto temporal: Random Walk de orden 2 (RW2)

La tendencia temporal γ_t se modela con un RW2, que penaliza la **segunda diferencia** (curvatura) de la tendencia:

$$\Delta^2 \gamma_t = \gamma_t - 2\gamma_{t-1} + \gamma_{t-2} \stackrel{\text{iid}}{\sim} \mathcal{N}(0, \sigma_\gamma^2) \quad (12)$$

La distribución conjunta es:

$$p(\boldsymbol{\gamma} \mid \sigma_\gamma^2) \propto \exp \left\{ -\frac{1}{2\sigma_\gamma^2} \sum_t (\gamma_t - 2\gamma_{t-1} + \gamma_{t-2})^2 \right\} \quad (13)$$

con matriz de precisión $\mathbf{Q}_\gamma = \sigma_\gamma^{-2} \mathbf{D}_2^\top \mathbf{D}_2$, donde $\mathbf{D}_2$ es la matriz de segundas diferencias (rango deficiente en 2).

El RW2 es preferible al RW1 para tendencias temporales en demografía porque:

- (i) refleja el supuesto de que la *velocidad del cambio* en mortalidad varía suavemente, no la mortalidad en sí misma; y
- (ii) produce extrapolaciones más razonables al proyectar períodos futuros.

2.5. Interacción espacio-temporal: IID

El término de interacción δ_{rt} captura variaciones residuales específicas de cada celda (región $\times$ período):

$$\delta_{rt} \stackrel{\text{iid}}{\sim} \mathcal{N}(0, \sigma_\delta^2) \quad (14)$$

Este componente absorbe heterogeneidad que no sigue un patrón espacial ni temporal coherente, como brotes localizados de una causa de muerte específica, o problemas de subregistro en un área y período particular.

3. Distribuciones a priori — Penalized Complexity Priors

Para los hiperparámetros de varianza $\sigma_\alpha^2, \sigma_\gamma^2, \sigma_\delta^2$ y el parámetro de mezcla ρ , INLA utiliza por defecto las distribuciones a priori de **Penalized Complexity (PC)** propuestas por Simpson et al. (2017). Estas priori penalizan la *complejidad innecesaria*: se contraen hacia el modelo más simple (sin efecto) a menos que los datos evidencien lo contrario.

3.1. PC prior para parámetros de escala (σ)

Para cada desviación estándar $\sigma > 0$, la PC prior especifica:

$$p(\sigma) = \lambda e^{-\lambda\sigma}, \quad \sigma > 0 \quad (15)$$

equivalente a la condición de cola: $\Pr(\sigma > u) = \alpha$. Por defecto INLA usa $\Pr(\sigma > 1) = 0.01$, lo que implica $\lambda = -\log(0.01) \approx 4.6$.

Esto significa que *a priori* se espera que las desviaciones estándar sean menores que 1 con probabilidad 99%, contrayendo el modelo hacia la homogeneidad a menos que los datos indiquen lo contrario.

3.2. PC prior para el parámetro de mezcla ρ (BYM2)

$$p(\rho) = \frac{\lambda}{2} e^{-\lambda\sqrt{1-\rho}} (1-\rho)^{-1/2} \quad (16)$$

Por defecto: $\Pr(\rho > 0.5) = 2/3$, indicando una ligera preferencia *a priori* por estructura espacial sobre heterogeneidad pura.

4. Inferencia por INLA

4.1. El objetivo: distribuciones posteriores marginales

Sea $\mathbf{x} = (\mu, \boldsymbol{\alpha}, \boldsymbol{\psi}, \boldsymbol{\gamma}, \boldsymbol{\delta})$ el campo latente Gaussiano y $\boldsymbol{\theta} = (\sigma_\alpha^2, \sigma_\gamma^2, \sigma_\delta^2, \sigma_\psi, \rho)$ los hiperparámetros. El objetivo es calcular:

$$p(x_i | \mathbf{D}) = \int p(x_i | \boldsymbol{\theta}, \mathbf{D}) p(\boldsymbol{\theta} | \mathbf{D}) d\boldsymbol{\theta} \quad (17)$$

$$p(\theta_j | \mathbf{D}) = \int p(\boldsymbol{\theta} | \mathbf{D}) d\boldsymbol{\theta}_{-j} \quad (18)$$

donde $\mathbf{D} = \{D_{xrt}\}$ son los datos observados.

4.2. La aproximación de Laplace anidada

La inferencia exacta es intratable. INLA (Rue et al., 2009) aproxima la distribución posterior de los hiperparámetros mediante una expansión de Laplace alrededor del modo condicional:

$$\tilde{p}(\boldsymbol{\theta} \mid \mathbf{D}) \propto \frac{p(\mathbf{D} \mid \mathbf{x}, \boldsymbol{\theta}) p(\mathbf{x} \mid \boldsymbol{\theta}) p(\boldsymbol{\theta})}{\tilde{p}_G(\mathbf{x} \mid \boldsymbol{\theta}, \mathbf{D})} \bigg|_{\mathbf{x}=\mathbf{x}^*(\boldsymbol{\theta})} \quad (19)$$

donde $\tilde{p}_G(\mathbf{x} \mid \boldsymbol{\theta}, \mathbf{D})$ es la aproximación Gaussiana de la posterior condicional, evaluada en su modo $\mathbf{x}^*(\boldsymbol{\theta}) = \arg \max_{\mathbf{x}} p(\mathbf{x} \mid \boldsymbol{\theta}, \mathbf{D})$.

4.3. Eficiencia computacional: estructura GMRF

La estructura **GMRF** (Gaussian Markov Random Field) de $\mathbf{x}$ implica que su matriz de precisión $\mathbf{Q}$ es **dispersa** (*sparse*). Esto permite:

$$\text{Costo de factorización de } \mathbf{Q}: \quad \mathcal{O}(n^{3/2}) \quad \text{vs.} \quad \mathcal{O}(n^3) \text{ (densa)} \quad (20)$$

haciendo que la aproximación sea computacionalmente factible para modelos con miles de parámetros latentes, a diferencia de MCMC que requeriría horas o días.

5. Construcción de la tabla de vida a partir de $\hat{m}_{xrt}^{\text{Bayes}}$

Una vez obtenidas las tasas de mortalidad suavizadas $\hat{m}_{xrt}^{\text{Bayes}}$ como medias posteriores del modelo INLA, se construye la tabla de vida mediante las siguientes transformaciones secuenciales.

5.1. Conversión $m_x \rightarrow q_x$

La probabilidad de morir en el intervalo $[x, x + n)$ se obtiene por la fórmula estándar (Preston et al., 2001):

$$q_x = \frac{n \cdot m_x}{1 + (n - a_x) \cdot m_x} \quad (21)$$

donde $n = 5$ (grupos quinquenales) y $a_x = 2.5$ (convención estándar para grupos cerrados; $a_0 = 2.0$ para el grupo 0–4 por mayor mortalidad infantil en edades tempranas).

Para el grupo abierto terminal: $q_{80+} = 1$ (certeza matemática de muerte).

5.2. Función de supervivencia l_x y muertes d_x

$$l_0 = 100\,000 \quad (\text{raíz o } \textit{radix} \text{ de la tabla}) \quad (22)$$

$$d_x = l_x \cdot q_x \quad (23)$$

$$l_{x+n} = l_x - d_x = l_x(1 - q_x) = l_0 \prod_{i=0}^x (1 - q_i) \quad (24)$$

5.3. Años-persona y esperanza de vida

$$L_x = \begin{cases} n \cdot l_x - (n - a_x) \cdot d_x & \text{grupos cerrados} \\ \frac{l_{80+}}{m_{80+}} & \text{grupo abierto 80+} \end{cases} \quad (25)$$

$$T_x = \sum_{i \geq x} L_i \quad (26)$$

$$e_x = \frac{T_x}{l_x} \quad (\text{esperanza de vida a la edad } x) \quad (27)$$

$$e_0 = \frac{T_0}{l_0} = \frac{T_0}{100\,000} \quad (\text{esperanza de vida al nacer}) \quad (28)$$

6. Ventajas del modelo para registros demográficos

1. **Coherencia con el proceso generador de datos.** Las defunciones son eventos discretos no negativos. La distribución Poisson es el modelo canónico para este tipo de proceso, derivado de los axiomas del proceso de Poisson, no de conveniencia computacional.
2. **No requiere varianza externa.** En encuestas, la varianza del estimador depende del diseño muestral y debe estimarse externamente (linearización de Taylor, jackknife). En registros, la varianza Poisson $\text{Var}(D) = \mu = Nm$ es intrínseca al modelo; no hay incertidumbre adicional por diseño muestral.
3. **Manejo natural de ceros.** Grupos de edad jóvenes o áreas pequeñas frecuentemente tienen $D_{xrt} = 0$. La distribución Poisson asigna probabilidad $P(D = 0) = e^{-\mu}$, que es positiva y coherente. Un modelo Gaussiano trataría este cero como una observación de baja varianza, generando estimaciones incorrectas.
4. **Préstamo de fortaleza multi-dimensional.** El modelo toma información prestada simultáneamente en tres dimensiones: *edad* (RW1), *espacio* (BYM2) y *tiempo* (RW2). Ningún método directo puede hacerlo sin imponer supuestos estructurales.
5. **Regularización adaptativa.** Las PC priors contraen hacia el modelo simple en proporción inversa a la evidencia en los datos. Áreas con muchas muertes observadas reciben poca regularización; áreas con pocas muertes se suavizan más, exactamente el comportamiento deseado.
6. **Velocidad computacional con INLA.** La aproximación INLA permite ajustar modelos de alta dimensión (cientos de efectos aleatorios) en minutos, mientras que MCMC equivalente requeriría horas o días, sin sacrificar la coherencia Bayesiana de la inferencia.

7. Correspondencia con el código en R

El código completo de implementación es el siguiente:

```
library(INLA)
library(SUMMER)
library(tidyverse)
library(dplyr)

set.seed(123)

# -----
# 1. Datos con grupos quinquenales del censo
# -----
regions <- c("Norte", "Centro", "Sur")

periods <- seq(1990, 2020, by = 5)

ages <- c("0-4", "5-9", "10-14", "15-19", "20-24",
          "25-29", "30-34", "35-39", "40-44", "45-49",
          "50-54", "55-59", "60-64", "65-69", "70-74",
          "75-79", "80+")

age_effect <- c(
  0.0150, 0.0005, 0.0003, 0.0008, 0.0012,
  0.0015, 0.0018, 0.0022, 0.0030, 0.0045,
  0.0070, 0.0110, 0.0170, 0.0260, 0.0400,
  0.0600, 0.1000
)

df <- expand.grid(
  region    = regions,
  period    = periods,
  agegroup  = ages
)

df$population <- round(runif(nrow(df), 800, 2000))

df$deaths <- rbinom(
  nrow(df),
  size = df$population,
  prob = rep(age_effect, each = length(regions) * length(periods)
))

# -----
# 2. Parametros de tabla de vida
# -----
age_params <- tibble(
  agegroup = ages,
```

```

n_interval = c(rep(5, length(ages) - 1), NA),
ax = c(
  2.0, 2.5, 2.5, 2.5, 2.5,
  2.5, 2.5, 2.5, 2.5, 2.5,
  2.5, 2.5, 2.5, 2.5, 2.5,
  2.5, NA
)
)
)

# -----
# 2. Matriz de adyacencia
# -----
adj <- matrix(0, 3, 3)
rownames(adj) <- colnames(adj) <- regions
adj["Norte", "Centro"] <- 1
adj["Centro", "Norte"] <- 1
adj["Centro", "Sur"] <- 1
adj["Sur", "Centro"] <- 1
Amat <- adj

# -----
# 3. Indices para INLA
# -----
df <- df %>%
  mutate(
    region_idx      = as.integer(factor(region, levels =
      regions)),
    period_idx      = as.integer(factor(period, levels =
      periods)),
    age_idx         = as.integer(factor(agegroup, levels =
      ages)),
    region_period_idx = as.integer(factor(paste(region, period))
    )
  )

g <- INLA::inla.read.graph(Amat)

# -----
# 4. Modelo INLA Poisson
# -----
formula_inla <- deaths ~
  f(age_idx,          model = "rw1",  constr = TRUE) +
  f(region_idx,       model = "bym2", graph = g, constr = TRUE)
  +
  f(period_idx,       model = "rw2",  constr = TRUE) +
  f(region_period_idx, model = "iid")

fit <- inla(
  formula  = formula_inla,
  family   = "poisson",
  data     = df,

```

```

E           = population,
control.predictor = list(compute = TRUE),
control.compute   = list(dic = TRUE, waic = TRUE)
)

# -----
# 5. Extraer tasas suavizadas
# -----
pred <- df %>%
  mutate(mx = pmax(fit$summary.fitted.values$mean, 1e-6)) %>%
  left_join(age_params, by = "agegroup")

# -----
# 6. Calcular qx
# -----
pred <- pred %>%
  mutate(
    qx = case_when(
      agegroup == "80+" ~ 1,
      TRUE ~ (n_interval * mx) /
        (1 + (n_interval - ax) * mx)
    ),
    qx = pmin(pmax(qx, 0), 1)
  )

# -----
# 7. Tabla de vida
# -----
life_tables <- pred %>%
  arrange(period, region, age_idx) %>%
  group_by(period, region) %>%
  group_modify(~ {
    df_lt <- .x
    k      <- nrow(df_lt)

    lx <- numeric(k + 1)
    dx <- numeric(k)
    Lx <- numeric(k)
    Tx <- numeric(k)

    lx[1] <- 100000

    for (i in seq_len(k)) {
      dx[i] <- lx[i] * df_lt$qx[i]
      lx[i+1] <- lx[i] - dx[i]

      if (df_lt$agegroup[i] == "80+") {
        Lx[i] <- ifelse(df_lt$mx[i] > 0, lx[i] / df_lt$mx[i], 0)
      } else {
        Lx[i] <- df_lt$n_interval[i] * lx[i] -
          (df_lt$n_interval[i] - df_lt$ax[i]) * dx[i]
      }
    }
  })

```

```

    }
  }

  Tx[k] <- Lx[k]
  for (i in (k - 1):1) Tx[i] <- Tx[i + 1] + Lx[i]

  tibble(
    agegroup = df_lt$agegroup,
    mx       = df_lt$mx,
    qx       = df_lt$qx,
    lx       = lx[1:k],
    dx       = dx,
    Lx       = Lx,
    Tx       = Tx,
    ex       = Tx / lx[1:k],
    e0       = Tx[1] / lx[1]
  )
}) %>%
ungroup()

# -----
# 8. Esperanza de vida
# -----
e0_resumen <- life_tables %>%
  distinct(period, region, e0) %>%
  arrange(region, period)

print(e0_resumen)

```

8. Guía línea por línea del código en R

Esta sección explica cada bloque del código de implementación, conectando cada instrucción con la teoría matemática desarrollada en las secciones anteriores.

8.1. Librerías y semilla aleatoria

```
library(INLA)
library(SUMMER)
library(tidyverse)
library(dplyr)
set.seed(123)
```

- `library(INLA)`: carga el motor de inferencia Bayesiana por Aproximación de Laplace Anidada Integrada (Rue et al., 2009). Es el núcleo computacional del análisis; sin él no es posible calcular las distribuciones posteriores del modelo jerárquico.
- `library(SUMMER)`: carga el paquete de Estimación en Áreas Pequeñas (Li et al., 2020). Aunque en este código se llama a `INLA` directamente, `SUMMER` provee funciones auxiliares para la manipulación de datos demográficos subnacionales.
- `library(tidyverse)` y `library(dplyr)`: colección de herramientas para manipulación de datos. `dplyr` ofrece los verbos `mutate()`, `filter()`, `group_by()` y `arrange()` que se usan extensivamente en el procesamiento posterior.
- `set.seed(123)`: fija la semilla del generador de números pseudoaleatorios. Garantiza **reproducibilidad**: cada ejecución del código produce exactamente los mismos datos simulados. Cualquier entero funciona como semilla.

8.2. Bloque 1: Construcción de los datos simulados

```
regions <- c("Norte", "Centro", "Sur")
periods <- seq(1990, 2020, by = 5)
ages <- c("0-4", "5-9", ..., "80+")
```

- `c()`: función *concatenar*; crea un vector con los elementos listados. Define las tres dimensiones del espacio de análisis: regiones $r \in \{1, 2, 3\}$, períodos $t \in \{1990, \dots, 2020\}$ y grupos de edad $x \in \{0-4, \dots, 80+\}$.
- `seq(1990, 2020, by = 5)`: genera la secuencia aritmética 1990, 1995, 2000, 2005, 2010, 2015, 2020 —siete quinquenios, coherente con la periodicidad de los censos latinoamericanos.

```
df <- expand.grid(region = regions, period = periods, agegroup =
  ages)
```

`expand.grid()` construye el **producto cartesiano** de los tres vectores, generando una fila por cada combinación posible región $\times$ período $\times$ grupo de edad: $3 \times 7 \times 17 = 357$ observaciones.

```
df$population <- round(runif(nrow(df), 800, 2000))
```

`runif(n, min, max)` simula n valores de una distribución uniforme continua $U(800, 2000)$. `round()` convierte a enteros para obtener conteos de población realistas. Representa la exposición N_{xrt} de la ecuación (2).

```
df$deaths <- rbinom(nrow(df), size = df$population,
                    prob = rep(age_effect, each = length(regions)
                               *length(periods)))
```

Simula conteos de defunciones bajo el modelo **Binomial**:

$$D_{xrt} \sim \text{Binomial}(N_{xrt}, q_x)$$

donde q_x es la probabilidad de muerte por grupo de edad (`age_effect`). Para tasas bajas ($q_x \ll 1$), $\text{Binomial}(N, q) \approx \text{Poisson}(Nq)$, justificando el modelo Poisson del análisis (ecuación 2).

`rep(age_effect, each = ...)` replica cada efecto de edad el número necesario de veces para que la longitud del vector coincida con `nrow(df)`.

8.3. Bloque 2: Parámetros de la tabla de vida

```
age_params <- tibble(
  agegroup = ages,
  n_interval = c(rep(5, length(ages) - 1), NA),
  ax = c(2.0, 2.5, 2.5, ..., 2.5, NA)
)
```

Crea una tabla auxiliar con los dos parámetros demográficos necesarios para convertir tasas m_x en probabilidades q_x (ecuación 21):

- **n_interval**: amplitud del intervalo de edad n . Todos los grupos tienen $n = 5$ (quinquenales), excepto el grupo abierto 80+ que recibe NA porque no tiene límite superior definido.
- **ax**: tiempo promedio vivido en el intervalo por quienes mueren (a_x en la ecuación 21). Por convención demográfica (Preston et al., 2001):
 - $a_0 = 2.0$ para el grupo 0–4: la mortalidad infantil se concentra en los primeros meses de vida, reduciendo el promedio por debajo de 2.5.
 - $a_x = 2.5$ para todos los demás grupos cerrados: supuesto de distribución uniforme de muertes dentro del intervalo.
 - NA para 80+: este grupo usa la fórmula especial $L_{80+} = l_{80+}/m_{80+}$ (ecuación 25).

8.4. Bloque 2b: Matriz de adyacencia espacial

```
adj <- matrix(0, 3, 3)
rownames(adj) <- colnames(adj) <- regions
adj["Norte", "Centro"] <- 1
```

```
adj["Centro", "Norte"] <- 1
adj["Centro", "Sur"] <- 1
adj["Sur", "Centro"] <- 1
Amat <- adj
```

Construye la **matriz de adyacencia** $\mathbf{W}$ de la ecuación (11):

$$W_{ij} = \begin{cases} 1 & \text{si las regiones } i \text{ y } j \text{ son vecinas} \\ 0 & \text{en caso contrario} \end{cases}$$

La topología resultante es una cadena lineal: Norte — Centro — Sur, donde Centro tiene dos vecinos ($n_{\text{Centro}} = 2$) y Norte y Sur tienen uno cada uno ($n_r = 1$). Esta estructura define el Laplaciano del grafo $\mathbf{Q}_W = \text{diag}(\mathbf{n}) - \mathbf{W}$ que aparece en el modelo ICAR.

La simetría $W_{ij} = W_{ji}$ es obligatoria: si i es vecino de j , entonces j es vecino de i .

8.5. Bloque 3: Índices para INLA

```
df <- df %>%
  mutate(
    region_idx = as.integer(factor(region, levels =
      regions)),
    period_idx = as.integer(factor(period, levels =
      periods)),
    age_idx = as.integer(factor(agegroup, levels =
      ages)),
    region_period_idx = as.integer(factor(paste(region, period))
  )
)
```

INLA requiere que todos los efectos aleatorios estén codificados como **índices enteros consecutivos** comenzando en 1. La secuencia `factor() → as.integer()` realiza esta conversión respetando el orden especificado en `levels`:

- `region_idx`: índice para el efecto espacial BYM2 (ψ_r , ecuación 9). Norte=1, Centro=2, Sur=3.
- `period_idx`: índice para la tendencia temporal RW2 (γ_t , ecuación 12).
- `age_idx`: índice para el efecto de edad RW1 (α_x , ecuación 7).
- `region_period_idx`: índice para la interacción espacio-temporal IID (δ_{rt} , ecuación 14). `paste(region, period)` crea identificadores únicos como "Norte 1990", "Centro 1995", etc.

```
g <- INLA::inla.read.graph(Amat)
```

Convierte la matriz de adyacencia $\mathbf{W}$ al formato interno de grafo que INLA necesita para construir la matriz de precisión ICAR $\mathbf{Q}_W$ (ecuación 11). La sintaxis `INLA::` llama explícitamente a la función del paquete INLA, evitando conflictos con otros paquetes.

8.6. Bloque 4: Especificación y ajuste del modelo INLA

```
formula_inla <- deaths ~
  f(age_idx,          model = "rw1",  constr = TRUE) +
  f(region_idx,       model = "bym2",  graph = g,  constr = TRUE)
  +
  f(period_idx,       model = "rw2",  constr = TRUE) +
  f(region_period_idx, model = "iid")
```

Define la fórmula del predictor lineal del Nivel 2 del modelo (Sección 3.1). Cada llamada a `f()` especifica un efecto aleatorio:

- `f(age_idx, model = "rw1", constr = TRUE)`: efecto de edad α_x modelado como Random Walk de orden 1 (Sección 3.2, ecuación 8). `constr = TRUE` impone $\sum_x \alpha_x = 0$ para identificabilidad.
- `f(region_idx, model = "bym2", graph = g, constr = TRUE)`: efecto espacial ψ_r como BYM2 (Sección 3.3, ecuación 9). `graph = g` provee la topología de vecindad. `constr = TRUE` impone $\sum_r \psi_r = 0$.
- `f(period_idx, model = "rw2", constr = TRUE)`: tendencia temporal γ_t como Random Walk de orden 2 (Sección 3.4, ecuación 13).
- `f(region_period_idx, model = "iid")`: interacción espacio-temporal δ_{rt} como efectos independientes (Sección 3.5, ecuación 14). No requiere restricción de suma cero.

```
fit <- inla(
  formula      = formula_inla,
  family       = "poisson",
  data         = df,
  E            = population,
  control.predictor = list(compute = TRUE),
  control.compute  = list(dic = TRUE, waic = TRUE)
)
```

- `family = "poisson"`: especifica la verosimilitud del Nivel 1 (ecuación 2): $D_{xrt} | m_{xrt} \sim \text{Poisson}(N_{xrt} \cdot m_{xrt})$.
- `E = population`: introduce la exposición N_{xrt} como *offset* en escala logarítmica (ecuación 5): $\log(\mu_{xrt}) = \log(N_{xrt}) + \eta_{xrt}$. Los `fitted.values` resultantes son directamente la tasa $m_{xrt} = \exp(\eta_{xrt})$, sin necesidad de dividir por población.
- `control.predictor = list(compute = TRUE)`: solicita a INLA calcular y almacenar la distribución posterior del predictor lineal para cada observación. Sin esta opción no se pueden extraer las tasas suavizadas con sus intervalos de credibilidad.
- `control.compute = list(dic = TRUE, waic = TRUE)`: calcula los criterios de comparación de modelos DIC (*Deviance Information Criterion*) y WAIC (*Widely Applicable Information Criterion*). Ambos penalizan la complejidad efectiva; menor valor indica mejor balance ajuste–parsimonia.

8.7. Bloque 5: Extracción de tasas suavizadas

```
pred <- df %>%
  mutate(mx = pmax(fit$summary.fitted.values$mean, 1e-6)) %>%
  left_join(age_params, by = "agegroup")
```

- `fit$summary.fitted.values$mean`: extrae la **media posterior** de la distribución de cada valor ajustado. En inferencia Bayesiana, la estimación puntual habitual es la media de la distribución posterior:

$$\hat{m}_{xrt}^{\text{Bayes}} = \mathbb{E}[m_{xrt} \mid \mathbf{D}] \approx \text{media posterior de INLA}$$

Gracias al *offset* `E = population`, estos valores ya son tasas m_{xrt} (no conteos); no se dividen por población.

- `pmax(..., 1e-6)`: *parallel maximum*, toma el máximo elemento a elemento entre el vector y 10^{-6} . Garantiza que ninguna tasa sea negativa o exactamente cero, condición necesaria para las transformaciones de la tabla de vida (no se puede calcular $L_{80+} = l_{80+}/m_{80+}$ si $m_{80+} = 0$).
- `left_join(age_params, by = "agegroup")`: une el *data frame* de predicciones con la tabla de parámetros demográficos por edad. Un *left join* conserva todas las filas del *data frame* izquierdo y añade las columnas correspondientes del derecho (aquí n_x y a_x), emparejando por la columna `agegroup`.

8.8. Bloque 6: Conversión $m_x \rightarrow q_x$

```
pred <- pred %>%
  mutate(
    qx = case_when(
      agegroup == "80+" ~ 1,
      TRUE ~ (n_interval * mx) / (1 + (n_interval - ax) * mx)
    ),
    qx = pmin(pmax(qx, 0), 1)
  )
```

- `case_when()`: equivalente vectorizado de múltiples `if-else`. Evalúa condiciones en orden y asigna el valor del primer caso verdadero:
 - **Caso 1 — grupo abierto 80+**: $q_{80+} = 1$ por definición demográfica. Toda persona que llega a los 80 años eventualmente muere dentro de ese grupo.
 - **Caso 2 — grupos cerrados**: aplica la fórmula estándar de conversión (ecuación 21):

$$q_x = \frac{n \cdot m_x}{1 + (n - a_x) \cdot m_x}$$

- `pmin(pmax(qx, 0), 1)`: doble truncamiento para garantizar $q_x \in [0, 1]$. `pmax(qx, 0)` elimina valores negativos; `pmin(..., 1)` elimina valores mayores que 1. Aunque la fórmula debería producir valores en el rango correcto, errores numéricos pueden generar desbordamientos.

8.9. Bloque 7: Construcción de la tabla de vida

```
life_tables <- pred %>%
  arrange(period, region, age_idx) %>%
  group_by(period, region) %>%
  group_modify(~ { ... }) %>%
  ungroup()
```

- `arrange(period, region, age_idx)`: ordena las filas. Es **crítico** ordenar por grupo de edad antes de construir la tabla de vida, ya que los cálculos son secuenciales: cada fila depende del resultado de la fila anterior (ecuaciones 23–24).
- `group_by(period, region)`: agrupa el *data frame* por período y región. Cada grupo recibirá su propia tabla de vida independiente.
- `group_modify(~{...})`: aplica la función anónima a cada grupo, devolviendo un *data frame*. Equivale a construir 21 tablas de vida separadas (3 regiones×7 períodos).

Dentro del bucle (for):

```
lx[1] <- 100000
```

Establece la raíz de la tabla (*radix*): una cohorte hipotética de 100 000 nacimientos (ecuación 22).

```
dx[i] <- lx[i] * df_lt$qx[i]
lx[i+1] <- lx[i] - dx[i]
```

Implementa las ecuaciones (23) y (24): $d_x = l_x \cdot q_x$ y $l_{x+n} = l_x - d_x$. La secuencialidad es esencial: no es posible calcular l_{x+n} sin conocer primero d_x , ni d_x sin conocer l_x .

```
if (df_lt$agegroup[i] == "80+") {
  Lx[i] <- ifelse(df_lt$mx[i] > 0, lx[i] / df_lt$mx[i], 0)
} else {
  Lx[i] <- df_lt$n_interval[i] * lx[i] -
    (df_lt$n_interval[i] - df_lt$ax[i]) * dx[i]
}
```

Implementa la ecuación (25) con sus dos casos:

- **Grupo abierto 80+**: $L_{80+} = l_{80+}/m_{80+}$. `ifelse(mx > 0, ..., 0)` protege contra división por cero.
- **Grupos cerrados**: $L_x = n \cdot l_x - (n - a_x) \cdot d_x$.

```
Tx[k] <- Lx[k]
for (i in (k - 1):1) Tx[i] <- Tx[i + 1] + Lx[i]
```

Acumulación de T_x de mayor a menor edad (ecuación 26): $T_k = L_k$ (último grupo); $T_i = T_{i+1} + L_i$ para el resto. El bucle recorre el vector *al revés* precisamente porque T_x requiere la suma de todos los L_i con $i \geq x$.

```
tibble(
  ...,
  ex = Tx / lx[1:k],
  e0 = Tx[1] / lx[1]
)
```

Calcula la esperanza de vida (ecuación 27) y la esperanza de vida al nacer (ecuación 28):

$$e_x = \frac{T_x}{l_x}, \quad e_0 = \frac{T_0}{100\,000}$$

$Tx[1] / lx[1]$ es idéntico a $Tx[1] / 100000$; se usa $lx[1]$ por generalidad.

8.10. Bloque 8: Resumen de la esperanza de vida al nacer

```
e0_resumen <- life_tables %>%
  distinct(period, region, e0) %>%
  arrange(region, period)

print(e0_resumen)
```

- `distinct(period, region, e0)`: elimina filas duplicadas, conservando solo las combinaciones únicas. Como la tabla de vida tiene 17 filas por grupo (región, período) y e_0 es el mismo para todas las edades dentro del grupo (es una constante del grupo, no varía con x), esto extrae una sola fila por (período, región).
- `arrange(region, period)`: ordena el resultado final primero por región y luego cronológicamente dentro de cada región, facilitando la lectura de la evolución temporal de e_0 .
- `print(e0_resumen)`: imprime en consola el *tibble* con 21 filas (3 regiones×7 períodos) mostrando la esperanza de vida al nacer suavizada por el modelo Bayesiano para cada combinación espacio-temporal.

Referencias

- Besag, J., York, J., & Mollié, A. (1991). Bayesian image restoration, with two applications in spatial statistics. *Annals of the Institute of Statistical Mathematics*, 43(1), 1–20.
- Clayton, D., & Kaldor, J. (1987). Empirical Bayes estimates of age-standardized relative risks for use in disease mapping. *Biometrics*, 43(3), 671–681.
- Fay, R.E., & Herriot, R.A. (1979). Estimates of income for small places: an application of James–Stein procedures to census data. *Journal of the American Statistical Association*, 74(366), 269–277.
- Li, Z.R., Martin, B.D., Dong, T.Q., Fuglstad, G.A., Paige, J., Riebler, A., Clark, S., & Wakefield, J. (2020). Space-time smoothing of survey outcomes using the R package SUMMER. *arXiv:2007.05117*.
- Preston, S., Heuveline, P., & Guillot, M. (2001). *Demography: Measuring and Modeling Population Processes*. Blackwell Publishers, Oxford.
- Riebler, A., Sørbye, S.H., Simpson, D., & Rue, H. (2016). An intuitive Bayesian spatial model for disease mapping that accounts for scaling. *Statistical Methods in Medical Research*, 25(4), 1145–1165.
- Rue, H., Martino, S., & Chopin, N. (2009). Approximate Bayesian inference for latent Gaussian models by using integrated nested Laplace approximations. *Journal of the Royal Statistical Society B*, 71(2), 319–392.
- Simpson, D., Rue, H., Riebler, A., Martins, T.G., & Sørbye, S.H. (2017). Penalising model component complexity: A principled, practical approach to constructing priors. *Statistical Science*, 32(1), 1–28.
- Yu, C.Y., Ševčíková, H., Raftery, A.E., & Curran, S.R. (2023). Probabilistic county-level population projections. *Demography*, 60(3), 915–937.